סקירת ספרות לשאלת המחקר: אמידת ה-NNT, NNE ו-EIN הישירים והעקיפים במחקרים תצפיתיים עם משתנים מתערבים חסרים

כותבי הסקירה: קרין שולמן גורן, דניאל ארמה

מוטיבציה

במחקר תצפיתי, הרצון להבין לא רק האם חשיפה משפיעה על תוצאה אלא כיצד היא פועלת, מוביל באופן טבעי לניתוח תיווך, כלומר פירוק האפקט הכולל לאפקט ישיר ולאפקט עקיף דרך מתווך.
אולם בפועל, ניתוח תיווך קלאסי (Natural Direct Effect and Natural Indirect Effect, האפקט מהחשיפה עצמה לעומת האפקט העובר דרך משתנים מתווכים) נשען על הנחות Exchangeability חזקות בין החשיפה למתווך ובין המתווך לתוצאה, והנחות אלו נוטות להיות מופרות בעולם אמיתי בגלל משתנים מתערבים חסרים.
משתנים אינסטרומנטליים (IV) תקפים מייצרים וריאציה אקראית בחשיפה, בעזרתם ניתן לעקוף חלק מההטיה שמגיעה ממשתנים מתערבים חסרים ולזהות אפקטים סיבתיים כאשר אלו נוכחים.
מאחר שהתוצאה לרוב בינארית והקשרים אינם ליניאריים, נדרש כלי אמידה שמאפשר לעבוד עם מודלים מבניים מוכללים. G-Estimation במסגרת Structural Mean Model ו- Generalized Structural Mean Model (מודלים המתארים את האפקט הסיבתי הממוצע של הטיפול על התוצאה) מהווה שיטה מרכזית לאמידה תחת משתנם אינסטרומנטליים.
המוטיבציה של הפרויקט היא לחבר בין שלוש מסגרות מתודולוגיות שבדרך כלל מיושמות בנפרד: תיווך סיבתי, IV, G-Estimation, ומדדי NNT. כדי לזהות מדדים ישירים ועקיפים מסוג:
Number Needed to Treat (NNT), Number Needed to be Exposed (NNE),
Exposure Impact Number (EIN) במקרה של משתנים מתערבים חסרים.
Number Needed to Treat - מדד המתאר את כמות האנשים בהם צריך לטפל כדי לקבל שינוי של אירוע אחד בתוצאה, בהתאם לכיוון ההשפעה (למשל כדי למנוע אירוע שלילי אחד).
Number Needed to be Exposed - מדד המתאר כמה יחידים מקבוצת הביקורת יש לחשוף (היפותטית) כדי לקבל שינוי של אירוע אחד בתוצאה, בהתאם לכיוון ההשפעה (למשל אירוע שלילי אחד נוסף).
Exposure Impact Number - מדד המתאר מכמה חשופים יש למנוע את החשיפה (או להפחית את החשיפה) כדי להשיג שינוי של אירוע אחד בתוצאה, שוב בהתאם לכיוון האפקט.

הצגת הבעיה

במחקרים תצפיתיים אין רנדומיזציה ולכן קיימים הבדלים שיטתיים בין קבוצת החשופים לקבוצת הביקורת, ולעיתים יש גם משתנים מתערבים חסרים שמטים אומדנים. מעבר לאפקט הכולל, נדרש גם פירוק מנגנוני לאפקט ישיר ולאפקט עקיף דרך מתווך. **עד לאחרונה לא היו שיטות אמידה ל-NNT, NNE, EIN ישירים ועקיפים, ובפרט לא תחת משתנים מתערבים חסרים.**

הפתרונות המובילים בספרות המחקרית

<u>רקע היסטורי ומסגרת התוצאות הפוטנציאליות</u>

בעשור האחרון התפתחה משמעותית שיטת הדיווח של תוצאות מחקרים קליניים ותצפיתיים. בעוד שמדדי סיכון יחסיים (כגון Odds Ratio) שלטו בשל תכונותיהם המתמטיות הנוחות, הספרות המודרנית מדגישה את הקושי בתרגומם להחלטות קליניות בשטח. נקודת המפנה היא עבודתם של Laupacis, Sackett, Roberts אשר הציגו את ה-Number Needed to Treat (NNT). מדד זה, המוגדר כהופכי של הפחתת הסיכון המוחלט (ARR), הציע לראשונה יחידת מידה המובנת לקלינאים: כמה חולים עלי לחשוף לטיפול כדי למנוע מקרה אחד של תוצאה שלילית? [1].

$$ARR = P(Y_1 = 1) - P(Y_0 = 1)$$

$$NNT = \frac{1}{ARR}$$

בסוף שנות ה-80 ותחילת שנות ה-90 חלה התקדמות באופן שבו מטפלים במשתנים מתערבים במחקרי תצפית. במקום להסתמך רק על תיקון באמצעות מודלי רגרסיה של התוצאה (Outcome Model), החלו לאמץ מסגרת סיבתית מפורשת המבוססת על תוצאות פוטנציאליות (Potential Outcomes).

במסגרת זו, ההנחות הנדרשות מוגדרות באופן ברור יותר, והאמידה מכוונת ישירות לאפקט סיבתי ולא לקשר אסוציאטיבי. בהקשר זה, Robins, Mark, Newey (1992) מציעים לתקן דרך מידול התוחלת המותנית של החשיפה בהינתן משתנים מתערבים, כחלק מהתשתית לשיטת G-Estimation. הרעיון המרכזי הוא שניתן לנצל מודל מפורש של תהליך הקצאת החשיפה (התניה על המשתנים המתערבים) כדי לתמוך בזיהוי ואמידה של השפעות סיבתיות כאשר מניחים שאין משתנים מתערבים חסרים [2].

מנקודת מבט של שאלת המחקר שלנו, שלב זה חשוב משום שהוא מחדד את גבולות היכולת של התאמה למשתנים מתערבים נמדדים. אם האמידה נשענת על כך שכל המשתנים המתערבים הרלוונטיים נמדדו, עולה באופן טבעי השאלה מה קורה כאשר הנחה זו אינה מתקיימת, כלומר כאשר קיימים משתנים מתערבים חסרים. מענה לבעיה זו מתפתח בהמשך הספרות במסגרת שימוש במשתנים אינסטרומנטליים (IV) ומודלים מבניים, שמאפשרים להתמודד עם משתנים מתערבים חסרים (תחת הנחות אחרות).

<u>הרחבת המדדים</u>

Bender, Blettner (2001) הרחיבו את השימוש ב-NNT למדדים נוספים שנועדו להתאים במיוחד למחקרי תצפית, שבהם ההשוואה בין קבוצת חשופים לקבוצת ביקורת אשר עשויות להיות שונות באופן שיטתי במאפייני הרקע שלהן [3]. במסגרת זו הוצגו שני מדדים מרכזיים:

- NNE (Number Needed to be Exposed)

$$\begin{cases} \dfrac{1}{P(Y_1 = 1|A = 0) - P(Y_0 = 1|A = 0)} & if\ bigger\ than\ 0 \\ \infty & else \end{cases}$$

- EIN (Exposure Impact Number)

$$\begin{cases} \dfrac{1}{(Y_1 = 1|A = 1) - P(Y_0 = 1|A = 1)} & if\ bigger\ than\ 0 \\ \infty & else \end{cases}$$

נקודה מתודולוגית מרכזית שמודגשת בעבודה זו היא שמכיוון שמדובר במחקר תצפיתי, חישוב נאיבי של מדדים אלו מתוך שיעורי האירועים הגולמיים עלול לשקף קשר אסוציאטיבי ולא השפעה סיבתית. לכן, כדי לפרש את NNE ו-EIN כמדדים סיבתיים המאפשרים לקבל החלטות בשטח, יש צורך לבצע אמידה באמצעות רגרסיה שמותאמת למשתנים מתערבים, כך שההשוואה תשקף ככל האפשר מצב המדמה אקראיות ביחס לחשיפה. פיתוח זה הניח את היסודות ל-G-Computation עבור מדדי אפקט במודלים של רגרסיה והעביר את הדיון מהשפעה ממוצעת כללית להשפעה ממוקדת קבוצה, כפי שניתן לראות במאמר של Sjölander (2018) שפיתח חבילת stdReg ב-R שנועדה לחשב מדדי השפעה סיבתיים [8]. כמו גם במאמרם של Vancak, Goldberg, Levine (2022) שפיתחו את Harmonic Mean NNT ואמידה עם שימוש במודלי רגרסיה [9].

<u>משתנים אינסטרומנטליים כמענה למשתנים מתערבים חסרים</u>

Hernán, Robins (2006) מציגים את שיטת המשתנים האינסטרומנטליים ככיוון מתודולוגי מרכזי להתמודדות עם משתנים מתערבים חסרים במחקרי תצפית. הרציונל הוא ששימוש במשתנה אינסטרומנטלי מתאים עשוי לאפשר אמידה עקבית של השפעה סיבתית גם כאשר ההנחה המקובלת שאין משתנים חסרים אינה מתקיימת [4]. עם זאת, המאמר מדגיש כי משתנים אינסטרומנטליים תקפים מגיעים במחיר הנחות חזקות, שלא ניתנות לבחינה אלא רק להצדקה תיאורטית:

- רלוונטיות (Relevance): משתנה אינסטרומנטלי משפיע על החשיפה.

$$Z \not\perp A \mid L$$

- הגבלת ההשפעה הישירה (Exclusion Restriction): אין למשתנה האינסטרומנטלי השפעה ישירה על התוצאה אלא רק דרך החשיפה.

$$Y(a, z) = Y(a) \ \ \forall a, z$$

- אקסוגניות (Independence): אין משתנים מתערבים חסרים בין המשתנה האינסטרומנטלי לתוצאה.

$$Z \perp Y(a) \mid L, U \ \ \forall a$$

בהקשר לשאלת המחקר, התרומה של Hernán, Robins היא בהבהרת המסר שהמשתנים האינסטרומנטליים אינם פתרון קסם, אלא מנגנון שמחליף בעיה אחת בסט הנחות חלופי,

שעלול להיפר בדרכים אחרות. לכן, המחברים מדגישים את החשיבות של ניסוח מבני של הבעיה לצורך זיהוי ואמידה.

<u>תיווך</u>

במקרים רבים אין די באמידת ההשפעה הכוללת של חשיפה על תוצאה, אלא נדרשת הבנת המנגנון של כיצד ההשפעה נוצרת. לשם כך, ניתוח תיווך מבקש לפרק את ההשפעה הכוללת לשני רכיבים, השפעה ישירה של החשיפה על התוצאה והשפעה עקיפה העוברת דרך משתנה מתווך.

Imai, Keele, Tingley (2010) מציעים מסגרת כללית לניתוח תיווך המבוססת על תוצאות פוטנציאליות, ומדגישים שהאתגר המרכזי אינו חישובי אלא שאלת הזיהוי, כלומר באילו תנאים ניתן לפרש את האומדנים כהשפעות סיבתיות ישירות ועקיפות, מאחר שבמחקרים תצפיתיים הנחות הזיהוי יכולות לא להתקיים, בייחוד כאשר קיימים משתנים מתערבים חסרים [5]. הם מדגישים את הצורך בניתוחי רגישות, המאפשרים לבחון כיצד עוצמת ההשפעה של משתנים מתערבים חסרים יכולה להטות את אומדן אפקט התיווך, ומהו תוקף המסקנות ביחס להפרת הנחות.

Pearl (2012) עוסק באותה בעיית תיווך סיבתי, אך במסגרת פורמלית שונה. בעוד ש-Imai, Keele, Tingley מנסחים את הדיון באמצעות תוצאות פוטנציאליות Pearl, מציג אותו באמצעות מודלים סיבתיים מבניים, נוסחת התיווך (mediation formula) וכלי הזיהוי של do-calculus. תרומתו המרכזית היא מיסוד ההבחנה בין Natural Direct Effect (NDE) ו- Natural Indirect Effect (NIE) והצגת תנאים שבהם ניתן לזהות רכיבים אלה מתוך נתונים נצפים [7].

אף שהמסגרת של Pearl שונה מבחינה פורמלית, גם אצלו ניתן לנסח את האפקטים הללו באמצעות משתנים פוטנציאליים לכן ההבדל אינו האם מדובר בניתוח סיבתי אלא בשפת הייצוג וכלי הזיהוי.

$$NDE = E[Y_{1,M_0} - Y_{0,M_0}]$$
$$NIE = E[Y_{1,M_1} - Y_{1,M_0}]$$

הבחנה זו מהווה בסיס תאורטי ישיר לפיתוחים מאוחרים יותר שמתרגמים את NIE, NDE למדדים קליניים שמאפשרים קבלת החלטות, כגון Direct and Indirect NNT.

לצד המסגרת התאורטית של ניתוח תיווך, קיימת גם בעיה פרקטית של תקשור גודל ההשפעה העקיפה והמשמעות היישומית שלה. בפרט, מדדים סטנדרטיים של תיווך (כגון NIE, NDE) מספקים פירוק סיבתי חשוב, אך לא תמיד מציעים פרשנות אינטואיטיבית לקבלת החלטות.

Preacher, Kelley (2011) דנים באסטרטגיות כמותיות לתקשור השפעות עקיפות ומציעים מדדי גודל-אפקט לתיווך שנועדו להפוך את התוצאות לנגישות יותר, תוך הדגשת הפער בין מובהקות סטטיסטית לבין משמעות יישומית [6]. נקודה זו מחזקת את המוטיבציה לפתח מדדי תיווך ביחידות שלפיהן קל יותר לקבל החלטות.

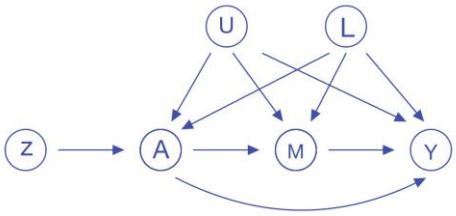

מבנה סיבתי של משתנה אינסטרומנטלי תקף ומודל תיווך. Y משתנה התוצאה, A הוא החשיפה, Z הוא המשתנה האינסטרומנטלי, M הוא המתווך, U מייצג את כלל המשתנים המתערבים החסרים ו-L מייצג את כלל המשתנים המתערבים המדודים. U ו-L משפיעים על Y, A, M. Z משפיע על M ו-Y אך ורק דרך A ואינו מתואם עם התוצאה על ידי U ו-L. A משפיע על Y במסלול ישיר ובמסלול עקיף שעובר דרך M.

<u>קבלת החלטות מותאמת אישית</u>

בשנים האחרונות גוברת ההבנה כי קבלת החלטות קליניות אינה יכולה להישען רק על מדדי אפקט ממוצעים באוכלוסייה, אלא מחייבת התאמה לפרופיל הפרט ולמאפייני תתי-אוכלוסיות. במסגרת זו, הודגש ההבדל בין מדדים ברמת אוכלוסייה (כגון ATE) לבין השפעות תלויות משתנים מתערבים נמדדים או פרטניות אשר עשויות להשתנות באופן מהותי בין אנשים או קבוצות סיכון שונות.

Mueller, Pearl (2023) מבחינים בין קבלת החלטות מבוססת אוכלוסייה, הנשענת על אפקטים ממוצעים בקבוצות דומות, לבין קבלת החלטות מותאמת אישית [10]. הבחנה זו מדגישה כי גם מדדים קליניים שימושיים ואינטואיטיביים כגון NNT, NNE ו EIN הם עדיין מדדים אגרגטיביים, ולכן אינם משקפים בהכרח תגובה אישית. עם זאת, חשיבותם היא שהם מדגישים כי אפקט ממוצע לבדו אינו מספיק, וכי נדרשות מסגרות שיאפשרו לזהות הבדלים בתגובה לטיפול בין יחידים ובין תתי קבוצות.

<u>שילוב משתנים אינסטרומנטליים עם NNT, NNE, EIN תחת משתנים מתערבים חסרים</u>

Vancak (2024) ו-Sjölander מציעים מסגרת סיבתית לאמידת NNT וכן המדדים הנגזרים NNE ו-EIN, באמצעות ניסוחם כמדדים המבוססים על תוצאות פוטנציאליות [11]. נקודת המוצא היא שבמחקר תצפיתי, כאשר קיימים משתנים מתערבים חסרים, אמידה סטנדרטית המבוססת על התאמה למשתנים מתערבים נמדדים בלבד אינה מבטיחה עקיבות, ולכן עלולה להוביל לפרשנות מוטעית של המדדים כ-Causal Quantity.

כמענה לבעיה זו, הם מציעים להשתמש במשתנים אינסטרומנטליים, תחת ניסוח פורמלי של שלוש הנחות התוקף: רלוונטיות, אקסוגניות ו Exclusion restriction. במסגרת זו, התרומה המתודולוגית המרכזית היא שילוב משתנים אינסטרומנטליים עם Generalized Structural Mean Model, כלומר מודל סיבתי דו שלבי שבו שלב אחד מתאר את האפקט הסיבתי באמצעות פרמטרים סיבתיים, ושלב שני מתאר את הקשר האסוציאטיבי בנתונים הנצפים לצורך זיהוי אותם פרמטרים. המאפשרים לבצע אמידה גם כאשר התוצאה בינארית, ובכך להרחיב את שיטות ה-Structural Mean Model הקלאסיות לסביבה יישומית שכיחה באפידמיולוגיה.

שימוש ב G-Estimation מאפשר פתרון של המשוואות הנובעות מהמודל המבני גם כאשר התוצאה

אינה ליניארית. המאמר מדגיש מספר היבטים המשפיעים באופן ישיר על איכות האמידה בהקשר של משתנים מתערבים חסרים. ראשית, משתנים אינסטרומנטליים חלשים עלולים להוביל לשונות גבוהה יותר. שנית, מודגשת הבחנה עקרונית בין חולשת המשתנה האינסטרומנטלי, שהיא בעיה שניתן להתמודד איתה באמצעות כלים סטטיסטיים מתאימים לבין הפרת האקסוגניות או ה-Exclusion, שהן הפרות מבניות המייצרות הטיה שאינה נעלמת גם במדגמים גדולים.
לבסוף, המחברים מציינים כי היישום המעשי של הגישה נשען על ארבעה רכיבי מודל: מודל לחשיפה, מודל לאינסטרומנט, מודל לתוצאה, ומודל ה־GSMM עצמו. לכן, האמידה רגישה למיספציפיקציה במפרט המשוואות של הרכיבים, מה שמדגיש את הצורך בבחירת מודלים זהירה ובבדיקות רגישות במידת האפשר.

<u>NNT עקיף וישיר</u>

Vancak, Sjölander (2025) מציגים את ההתפתחות העדכנית, שבה נעשה חיבור בין התיווך הסיבתי לבין מדדי NNT. תחילה הגדירו את ניתוח התיווך באמצעות הגדרות של Natural Direct Effect (NDE) ו-Natural Indirect Effect (NIE), ובהמשך התבססו כלים לאמידת NNT מותאם למשתנים מתערבים ולמדדי NNT, NNE, EIN גם בסביבה תצפיתית מורכבת. הם מגדירים את רכיבי התיווך ל-NNT ישיר ועקיף [12].
המחברים מציגים את התפתחות התחום כרצף מתודולוגי מצטבר, המחבר בין מסגרות לזיהוי אפקטים ישירים ועקיפים בתיווך (כגון אלו של Imai ושל Pearl), גישות אמידה מבוססות G-Computation למדדי אפקט סיבתיים (למשל יישומים בסגנון stdReg), והרחבות המאפשרות לנסח NNT באופן התלוי במשתנים מתערבים המאפשר קבלת החלטות.
באופן זה, הם מבהירים כי ההגדרה של Direct and Indirect NNT אינה תוצאה של מניפולציה אלגברית בלבד, אלא נגזרת של שילוב שתי תשתיות משלימות: זיהוי סיבתי של מסלולי ההשפעה (באמצעות NDE, NIE ותנאי הזיהוי שלהם), ומיפוי של אפקטים סיבתיים למדד המכמת את גודל התועלת במונחים של "כמה נדרש" כדי להשיג שינוי של אירוע אחד בתוצאה.

מטרת הצעת המחקר

הפרויקט יישם את המסגרות העדכניות כדי לאמוד NNT, NNE, EIN ישירים ועקיפים במחקרים תצפיתיים עם משתנים מתערבים חסרים באמצעות תוצאות פוטנציאליות, משתנים אינסטרומנטליים, G-Estimation.

סיכום

סקירה זו משרטטת את המעבר המתודולוגי משימוש במדדי אפקט יחסיים מסורתיים למדדי NNT (NNT, NNE ו-EIN), המנגישים את התועלת הקלינית לקבלת החלטות מותאמת אישית.
ניכר כי התחום התפתח משמעותית עם שילובן של מסגרות סיבתיות מבוססות תוצאות פוטנציאליות, המאפשרות אמידה עקיבה גם בתנאים מורכבים של מחקרים תצפיתיים. הנקודה המרכזית העולה מהסקירה היא היכולת המודרנית לפרק את ההשפעה הכוללת לרכיבים ישירים ועקיפים ולתרגמם

למונחי NNT, תוך שימוש במשתנים אינסטרומנטליים ו-G-Estimation כמענה מרכזי לבעיית המשתנים המתערבים החסרים. לצד התקדמות זו, הסקירה מצביעה על מספר אתגרים ופערים. השימוש במשתנים אינסטרומנטליים תלוי בהנחות חזקות ורגיש מאוד למיספציפיקציה של המודלים, מה שמחייב בחירה זהירה של כלים סטטיסטיים וניתוחי רגישות מעמיקים.
פרויקט הגמר יעסוק בהצעה ומימוש של אמדנים בנוכחות משתנים מתערבים חסרים.

מקורות

[1] Andreas Laupacis, David L Sackett, and Robin S Roberts. An assessment of clinically useful measures of the consequences of treatment. New England Journal of Medicine, 318(26):1728–1733, 1988.

[2] James M. Robins, Steven D. Mark and Whitney K. Newey. Estimating exposure effects by modelling the expectation of exposure conditional on confounders. Biometrics, 48(2):479–495, 1992.

[3] Ralf Bender and Maria Blettner. Calculating the "number needed to be exposed" with adjustment for confounding variables in epidemiological studies. Journal of Clinical Epidemiology, 55(5):525–530, 2002.

[4] Miguel A. Hernán and James M. Robins. Instruments for causal inference: an epidemiologist's dream? Epidemiology, 17(4):360–372, 2006.

[5] Kosuke Imai, Luke Keele and Dustin Tingley. A general approach to causal mediation analysis. Psychological Methods, 15(4):309–334, 2010.

[6] Kristopher J. Preacher and Ken Kelley. Effect size measures for mediation models: quantitative strategies for communicating indirect effects. Psychological Methods, 16(2):93–115, 2011.

[7] Judea Pearl. The causal mediation formula—a guide to the assessment of pathways and mechanisms. Prevention Science, 13(4):426–436, 2012.

[8] Arvid Sjölander. Estimation of causal effect measures with the R-package stdreg. European Journal of Epidemiology, 33(9):847–858, 2018.

[9] Valentin Vancak, Yair Goldberg, and Stephen Z Levine. The number needed to treat adjusted for explanatory variables in regression and survival analysis: Theory and application. Statistics in Medicine, 41(17):3299–3320, 2022.

[10] Scott Mueller and Judea Pearl. Personalized decision making–a conceptual introduction. Journal of Causal Inference, 11(1):20220050, 2023.

[11] Valentin Vancak, and Arvid Sjölander. Estimation of the number needed to treat, the number needed to be exposed, and the exposure impact number with instrumental variables. Epidemiologic Methods, 13(1):20230034, 2024.

[12] Valentin Vancak and Arvid Sjölander. Definition, identification, and estimation of the direct and indirect number needed to treat. Epidemiologic Methods, vol. 14, no. 1, pp. 20250018, 2025.